Classificação de ocupação de vagas com métodos clássicos

T1 | INE5443 - Reconhecimento de Padrões | 2026-2

Repositório: Soul-Legend/VisaoComputacional

1. Introdução e objetivo

Uma vaga de estacionamento pode mudar bastante de aparência ao longo do dia. A passagem de um carro altera as cores, as texturas e os contornos da imagem, enquanto sombras, reflexos e chuva também modificam essas mesmas pistas. O desafio deste trabalho é reconhecer a ocupação da vaga apesar dessas variações.

Para estudar o problema, partimos de uma tarefa bem delimitada: receber uma imagem já recortada de uma vaga e classificá-la como **livre (0)** ou **ocupada (1)**. A localização das vagas na imagem completa é considerada conhecida. Assim, podemos concentrar a análise na forma de representar visualmente cada recorte e na qualidade da classificação obtida.

Comparamos três representações: HSV, que descreve cores; LBP, que resume texturas; e HOG, que representa orientações de gradientes. Também avaliamos a combinação dos três descritores. Em todos os casos, usamos o mesmo classificador, uma SVM linear. Isso permite investigar a seguinte pergunta: **qual representação é escolhida na validação e como ela se comporta em imagens de outros dias?**

Visão geral do experimento

Foram utilizadas 10.000 imagens reais do CNR-EXT [1], distribuídas entre treino, validação e teste. O treino serve para aprender o classificador; a validação, para escolher a configuração; e o teste, para avaliar a escolha em dados reservados. Os descritores foram comparados nas mesmas imagens, seguindo um protocolo definido antes da consulta ao teste.

O modelo selecionado foi **LBP + SVM**, com C=0.01. Seu F1 macro foi **0.9028** na validação e **0.8998** no teste, com acurácia de **0.9020**. Como referência, um classificador que sempre prevê a classe mais frequente do treino obteve F1 macro de **0.3649**. As seções seguintes explicam como esses números foram obtidos e o que eles permitem concluir.

Primeiro, apresentamos os métodos com exemplos visuais. Em seguida, descrevemos os dados e o protocolo experimental, para então analisar os resultados por classe, clima e tipo de erro. Os detalhes necessários para reproduzir o estudo ficam reunidos ao final e na documentação do repositório.

O trabalho cobre a abordagem clássica do T1. A comparação com redes neurais ficará para o T2, usando o mesmo teste. Os resultados atuais se referem a dias distintos de um único estacionamento; sua aplicação a novos locais exigirá outra avaliação.

2. Como os métodos representam a imagem

Antes de classificar uma vaga, precisamos transformar seus pixels em uma descrição numérica. Cada descritor destaca um aspecto da cena. Para tornar essa diferença concreta, as Figuras 1 a 3 usam o mesmo par de imagens de treino: a vaga 204 da câmera 6, livre às 07h46 e ocupada às 08h46 de 12/11/2015. Como os horários diferem, os exemplos também apresentam mudanças de iluminação. Sua finalidade é explicar os métodos.

2.1. HSV: descrever a distribuição das cores

O espaço HSV separa três propriedades: **H (matiz)** identifica a tonalidade; **S (saturação)** indica o quanto a cor se afasta do cinza; e **V (valor)** representa sua intensidade. Na Figura 1, os canais S e V aparecem em cinza: quanto mais claro o pixel, maior o valor do canal.

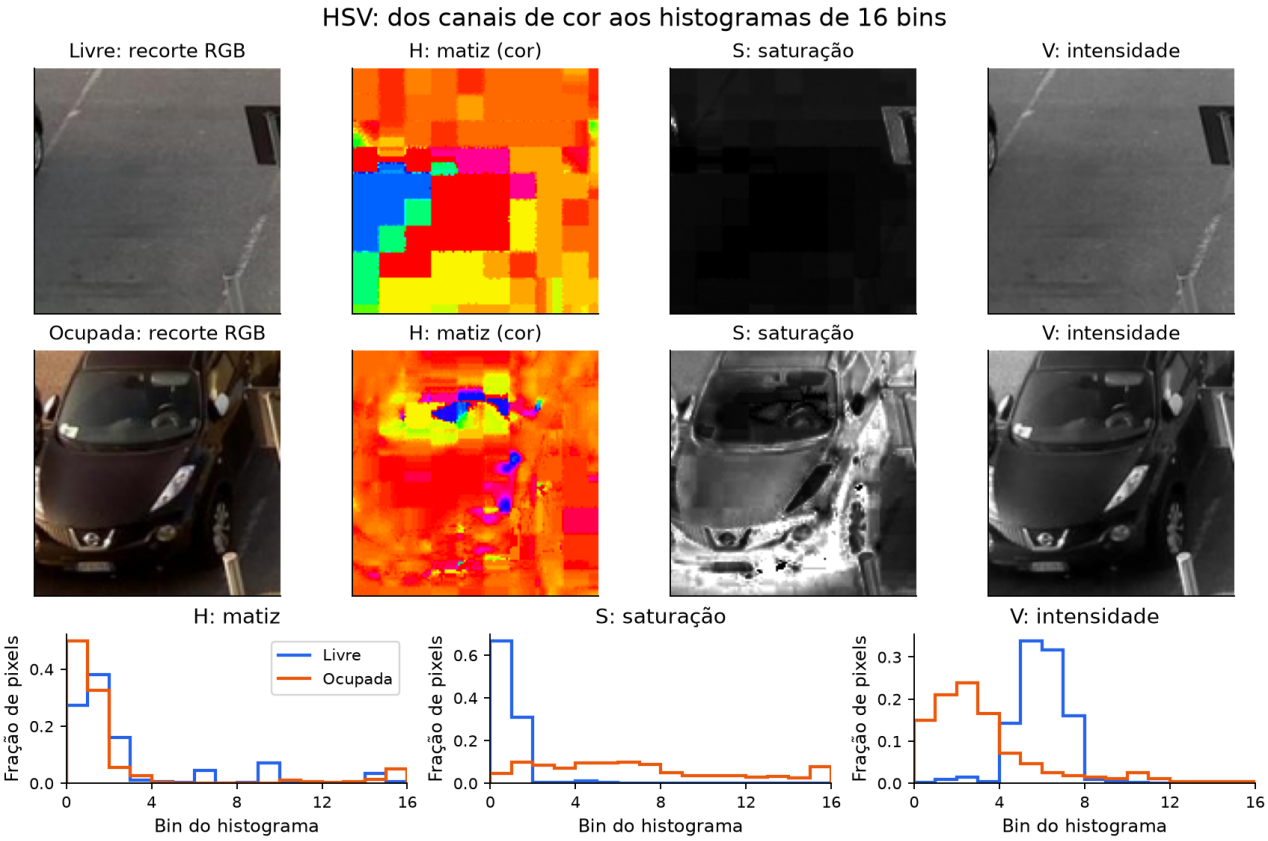


Figura 1. Canais HSV e seus histogramas para uma vaga livre e ocupada. Origem: CNRPark+EXT. O mapa de H usa cores para visualizar a matiz; ele não reconstrói a imagem original.

No exemplo, a vaga livre concentra pixels com baixa saturação. A presença do carro distribui esses valores por mais intervalos e também modifica a intensidade. Em regiões quase cinzentas, a matiz pode oscilar mesmo quando a diferença de cor é pouco perceptível; por isso, H deve ser interpretado junto de S.

Para gerar o descritor, dividimos os valores de cada canal em 16 intervalos, chamados bins, e contamos a fração de pixels em cada um. Cada histograma soma um. Ao reunir os três, obtemos **48 características**. H usa o intervalo [0,180) do OpenCV, e S e V usam [0,256).

Essa representação é compacta, mas perde a posição das cores: imagens diferentes podem ter histogramas parecidos. A próxima representação procura informação na textura local.

2.2. LBP: resumir as texturas locais

Uma textura descreve como as intensidades variam em pequenas regiões. Mesmo sem considerar a cor, asfalto, vidros, carroceria e detalhes do veículo podem produzir padrões locais diferentes. O **Local Binary Patterns (LBP)** explora essa informação comparando cada pixel com seus vizinhos [3].

Primeiro, convertemos a imagem para cinza. Para cada pixel, comparamos sua intensidade com oito vizinhos distribuídos em um círculo de raio um. O padrão dessas comparações recebe um código. Na versão uniforme adotada aqui, os códigos 0 a 8 representam padrões uniformes, com até duas transições entre comparações positivas e negativas ao percorrer o círculo; o código 9 reúne os demais padrões.

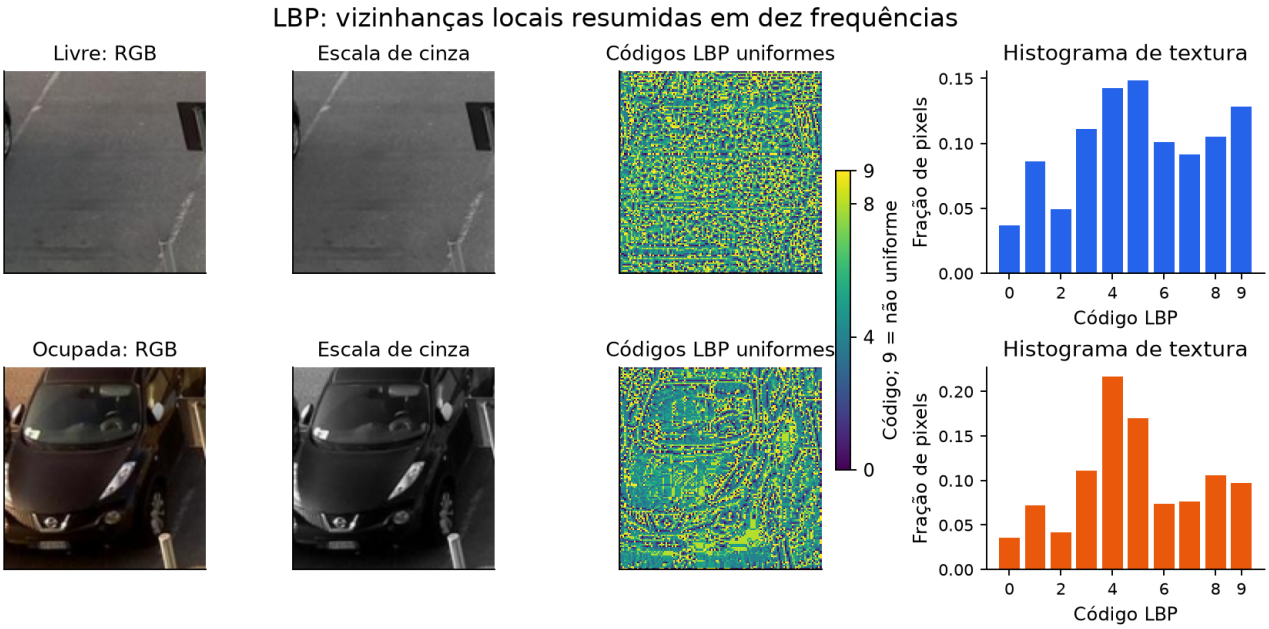


Figura 2. Da imagem em cinza ao mapa de códigos LBP e ao histograma de textura. As cores indicam códigos locais; não identificam automaticamente carro ou pavimento.

O mapa conserva a posição de cada código e ajuda a enxergar onde os padrões mudam. No exemplo ocupado, é possível acompanhar estruturas do veículo. Já o vetor entregue ao classificador contém somente a frequência dos códigos: contamos quantas vezes cada um aparece e normalizamos o histograma para soma um. O resultado tem **dez características**.

Os gráficos mostram que a distribuição desses padrões difere entre os dois recortes. Isso ilustra a informação disponível ao modelo, mas dois exemplos não bastam para afirmar que uma textura identifica a classe em todas as condições. Sombras, vegetação e marcações também podem modificar as frequências.

LBP oferece uma descrição pequena e rápida de extrair. Em contrapartida, seu histograma global perde a localização das texturas e, nesta configuração, examina apenas uma escala. Para preservar mais informação sobre a organização dos contornos, avaliamos também o HOG.

2.3. HOG: representar contornos e suas orientações

O gradiente mede a mudança de intensidade entre pixels próximos. Mudanças fortes aparecem em bordas, como nos limites da carroceria e dos vidros. O **Histograms of Oriented Gradients (HOG)** resume a direção dessas mudanças em pequenas regiões da imagem [2].

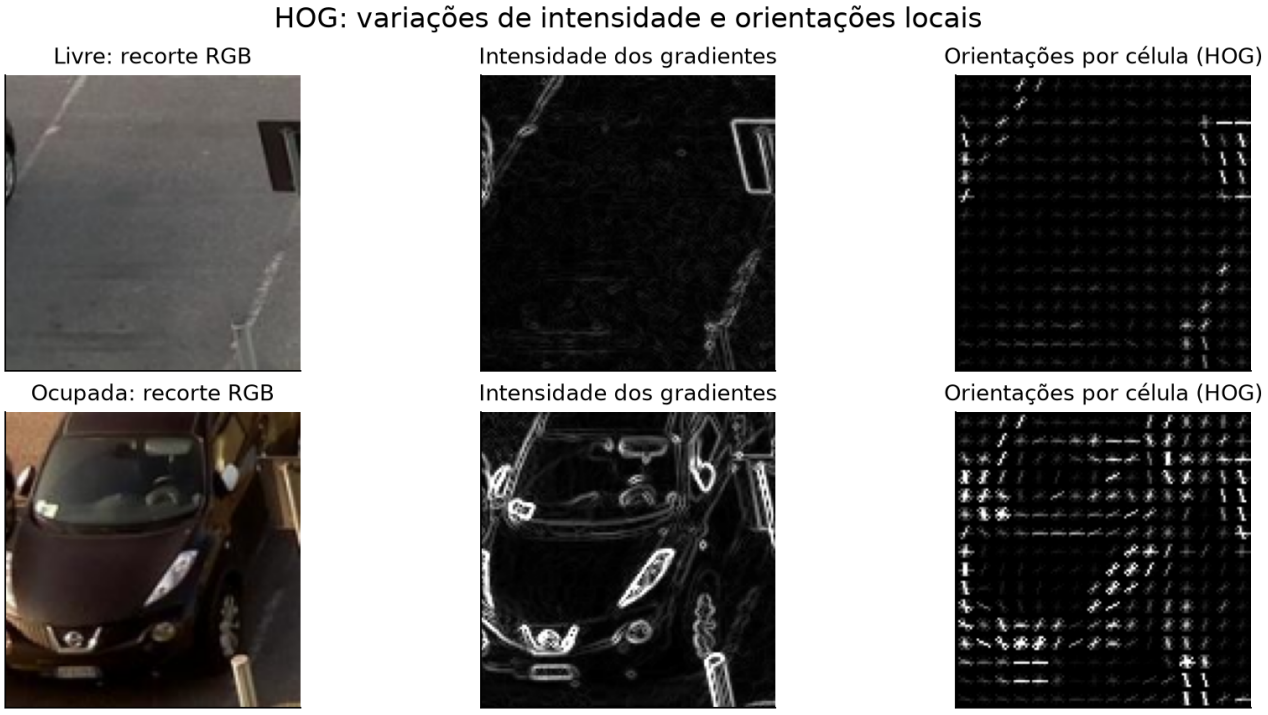


Figura 3. Recortes originais, intensidade dos gradientes e orientações por célula. O contraste foi realçado com a mesma escala nos dois exemplos, somente para visualização.

Na vaga ocupada, os contornos do carro introduzem várias orientações. A vaga livre também contém gradientes, vindos de marcações e outros elementos da cena. O HOG organiza essas respostas em células 8 × 8, com nove orientações, e normaliza blocos de 2 × 2 células pelo método L2-Hys. Em imagens de 128 × 128, o vetor final possui **8.100 características**. O desenho da figura resume orientações por célula; o vetor usado no treinamento inclui a normalização dos blocos e não deve ser confundido com esse desenho.

2.4. Das características à classificação



Figura 4. O mesmo fluxo é usado para cada descritor e para sua combinação.

A SVM aprende uma fronteira que separa exemplos livres e ocupados no espaço das características [4]. Antes do ajuste, o StandardScaler padroniza cada componente com a média e o desvio do treino. O parâmetro C controla a penalização de erros durante o ajuste. Usamos LinearSVC, com regularização L2 e perda quadrática hinge.

Na combinação, reunimos HSV, LBP e HOG em um vetor de **8.158 componentes**. A hipótese é que cor, textura e contornos forneçam informações complementares. A padronização ocorre por componente, sem pesos específicos para os três blocos. Seu benefício será verificado pelos experimentos, junto do aumento de dimensão e custo.

3. Dataset e preparação dos dados

O CNRPark+EXT foi disponibilizado por Amato e colaboradores para estudar a ocupação de vagas [1]. Utilizamos apenas sua extensão **CNR-EXT**, composta por 144.965 recortes de nove câmeras, capturados em 23 dias. As imagens estão organizadas por clima: SUNNY (ensolarado), OVERCAST (nublado) e RAINY (chuvoso). As listas dos autores fornecem os rótulos e as partições de treino, validação e teste.

Antes da amostragem, conferimos todas as imagens dessas listas. Encontramos **0 imagens ilegíveis** e excluímos **38 registros com pixels idênticos e rótulos conflitantes**. Foram removidas **0 duplicatas adicionais**. A identidade dos arquivos foi verificada pelo conteúdo e pelos pixels decodificados, incluindo suas dimensões. Essa limpeza ocorreu antes do treinamento.

Em seguida, selecionamos 10.000 imagens, preservando aproximadamente as proporções de classe, câmera e clima dentro de cada partição oficial. A amostragem usa semente 42 e cotas proporcionais, com distribuição dos maiores restos para fechar os tamanhos exatos. Nenhuma imagem foi transferida entre as partições.

Partição	Livre	Ocupada	Total
treino	3470	3530	7000
validacao	420	1080	1500
teste	638	862	1500

Tabela 1. Composição do subconjunto utilizado no estudo.

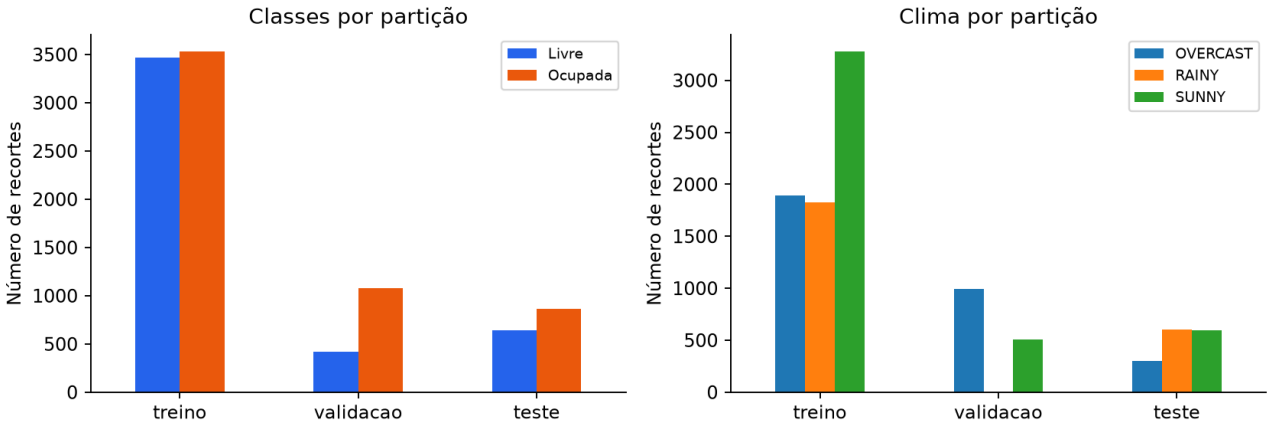


Figura 5. Quantidade de imagens por classe e clima em cada partição.

O teste mantém a proporção observada nas listas, sem balanceamento artificial. Como essa proporção varia entre as partições, a avaliação precisa considerar o desempenho das duas classes, além da acurácia total. Esse ponto motiva a escolha do F1 macro na seleção.

O arquivo foi obtido da release oficial dos autores, que informa licença ODbL 1.0. URL, tamanho e hash do download estão registrados na auditoria. Os exemplos visuais deste relatório são derivados do CNRPark+EXT e mantêm sua atribuição.

4. O que muda entre treino e teste



Figura 6. Exemplos de treino nas duas classes e em diferentes condições climáticas. Origem: CNRPark+EXT, subconjunto CNR-EXT.

Os exemplos mostram que a classificação depende de mais do que a presença de uma grande região correspondente a um carro. A perspectiva muda entre câmeras; árvores e outros elementos encobrem partes das vagas; e sombras podem alterar a aparência do pavimento. Essas variações ajudam a compreender por que descritores diferentes podem cometer erros diferentes.

Todas as imagens são redimensionadas para **128 × 128** antes da extração, para manter a dimensão dos vetores constante. A leitura converte explicitamente BGR para RGB. HOG e LBP recebem a versão em cinza inteiro; HSV utiliza a imagem colorida. Não aplicamos aumento de dados ou transformações aleatórias.

Na amostra final, treino e teste compartilham **9 câmeras** e **164 identificadores de vagas**. Por outro lado, há **0 datas** e **0 capturas de câmera e horário em comum** entre eles. Portanto, o experimento avalia dias diferentes das mesmas câmeras e vagas.

Essa distinção orienta a leitura dos resultados. A separação por dias reduz a proximidade temporal entre treino e teste, mas o fundo e a geometria das vagas permanecem reconhecíveis. Para avaliar uma câmera ou um estacionamento novo, seria necessário reservar esses cenários em outro protocolo. O estudo atual fornece uma referência para o problema nas condições descritas, sem demonstrar essa generalização mais ampla.

5. Como os modelos foram comparados

Aprender, escolher e avaliar

Cada configuração foi ajustada somente nas **7.000 imagens de treino**. O StandardScaler aprende a média e o desvio nesse conjunto e apenas transforma validação e teste. Para cada representação, avaliamos quatro valores de C: **0,01; 0,1; 1; 10**. Os parâmetros dos descritores permaneceram fixos, conforme a seção 2.

A escolha considera o maior F1 macro na validação, arredondado a quatro casas decimais. Empates favorecem o vetor de menor dimensão e depois o menor C. A regra define a melhor configuração de cada representação e o modelo escolhido para a discussão principal. Os modelos não foram reajustados com os dados de validação.

Depois da escolha, os modelos e suas configurações foram congelados. Só então executamos um lote de avaliação no teste, usando as mesmas imagens para todos. O resultado desse lote não foi usado para ajustar os métodos. Incluímos ainda uma referência simples: prever sempre a classe mais frequente no treino, para verificar o quanto cada método supera uma decisão que não observa a imagem.

Como interpretar as métricas

A **acurácia** é a fração total de previsões corretas. Ela oferece uma visão geral, mas pode ocultar diferenças entre as classes. Por exemplo, prever sempre ocupada acerta muitos casos quando essa classe é predominante, embora nenhuma vaga livre seja reconhecida.

A **precisão** de uma classe indica quantas de suas previsões estão corretas. O **recall** indica quantos exemplos reais dessa classe foram encontrados. O **F1** combina precisão e recall pela média harmônica. Por fim, o **F1 macro** calcula a média dos F1 das duas classes, atribuindo a elas o mesmo peso. Por esse motivo, ele foi adotado para a seleção.

Nas matrizes de confusão, as linhas representam os rótulos reais e as colunas, as previsões. Também apresentamos métricas por clima, acompanhadas do tamanho e da composição de cada grupo. Os rótulos usados nos cálculos são sempre [0,1], com resultado zero quando um denominador é nulo. As pontuações da SVM não são tratadas como probabilidades calibradas.

Condições de execução

O SVM usa semente 42, escolha automática do modo dual, tolerância 1e-4 e limite de 20.000 iterações. Uma falha de convergência interrompe o ajuste. A extração mede leitura, verificação da imagem, redimensionamento e cálculo do descritor; o treinamento inclui a padronização; e a inferência mede padronização e previsão em lote. Os tempos por imagem são médias desse lote, sem estimativa de variabilidade entre execuções.

O manifesto e os artefatos são identificados por hashes. O código verifica sua integridade e bloqueia a sobrescrita do teste já avaliado. As instruções de reprodução estão no repositório, junto dos registros de parâmetros e versões.

6. Resultados de validação e teste

A Tabela 2 reúne todos os ajustes previstos. Ela mostra como cada representação respondeu à mudança de C e permite acompanhar a escolha feita antes da avaliação final.

Descritor	C	Dimensão	F1 macro	Ajuste (s)
HOG	0.01	8100	0.8762	8.545
HOG	0.1	8100	0.8741	9.476
HOG	1	8100	0.8717	10.020
HOG	10	8100	0.8717	10.547
HSV	0.01	48	0.7457	0.027
HSV	0.1	48	0.7463	0.028
HSV	1	48	0.7463	0.028
HSV	10	48	0.7463	0.028
LBP	0.01	10	0.9028	0.005
LBP	0.1	10	0.9021	0.006
LBP	1	10	0.9021	0.005
LBP	10	10	0.9028	0.005
Combinação	0.01	8158	0.9027	5.952
Combinação	0.1	8158	0.9003	5.978
Combinação	1	8158	0.9003	4.823
Combinação	10	8158	0.8995	6.108

Tabela 2. F1 macro na validação e tempo de ajuste, incluindo a padronização.

A validação selecionou **LBP + SVM**, com C=0.01 e F1 macro **0.9028**. LBP e a combinação ficaram muito próximos nessa etapa. Essa diferença pequena define a escolha pelo protocolo adotado, mas não demonstra superioridade estatística.

Descritor	Acurácia	F1 macro	C
HOG	0.9127	0.9114	0.01
HSV	0.8080	0.8051	0.1
LBP	0.9020	0.8998	0.01
Combinação	0.9307	0.9295	0.01
Majoritário	0.5747	0.3649	-

Tabela 3. Avaliação nas mesmas 1.500 imagens reservadas para teste.

O modelo selecionado alcançou F1 macro **0.8998** e acurácia **0.9020**. O ganho de F1 macro sobre a referência majoritária foi **0.5349**. No teste, a combinação dos três descritores obteve o maior F1 macro. A escolha feita na validação foi mantida. Essa mudança de ranking mostra que a ordenação observada na validação não se reproduz exatamente em outros dias. O teste permite observar essa diferença, sem redefinir a escolha.

7. O desempenho de cada classe

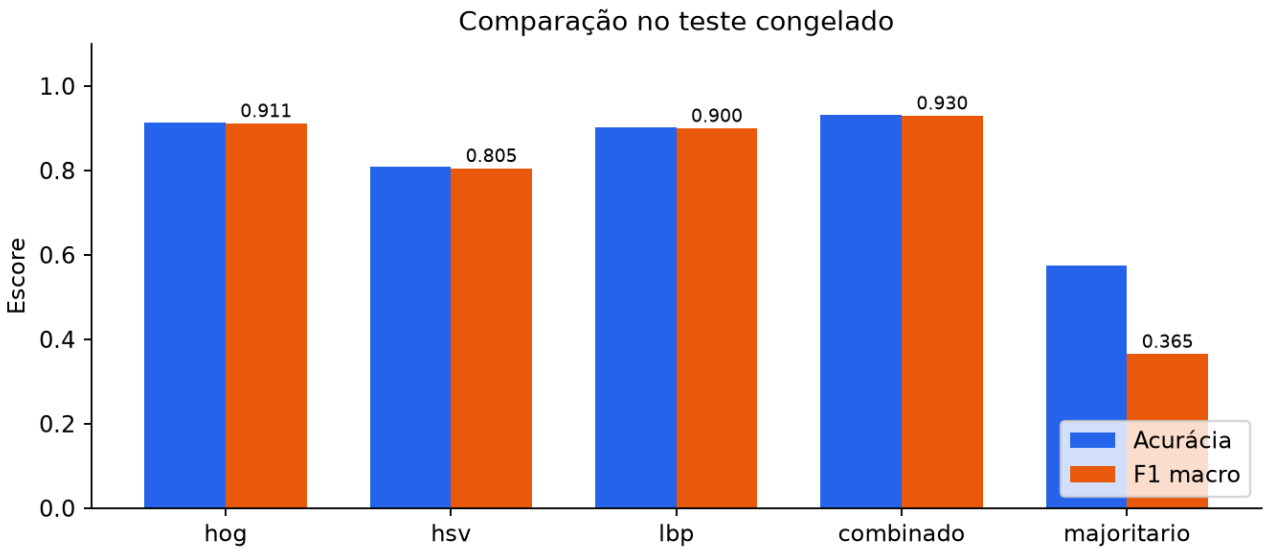


Figura 7. Acurácia e F1 macro no teste. As diferenças são descritivas, sem teste de significância.

Descritor	P livre	R livre	F1 livre	P ocup.	R ocup.	F1 ocup.
HOG	0.870	0.934	0.901	0.948	0.897	0.922
HSV	0.758	0.806	0.781	0.849	0.810	0.829
LBP	0.883	0.887	0.885	0.916	0.913	0.915
Combinação	0.897	0.945	0.921	0.958	0.920	0.938
Majoritário	0.000	0.000	0.000	0.575	1.000	0.730

Tabela 4. Precisão (P), recall (R) e F1 por classe. Os suportes estão na Tabela 1.

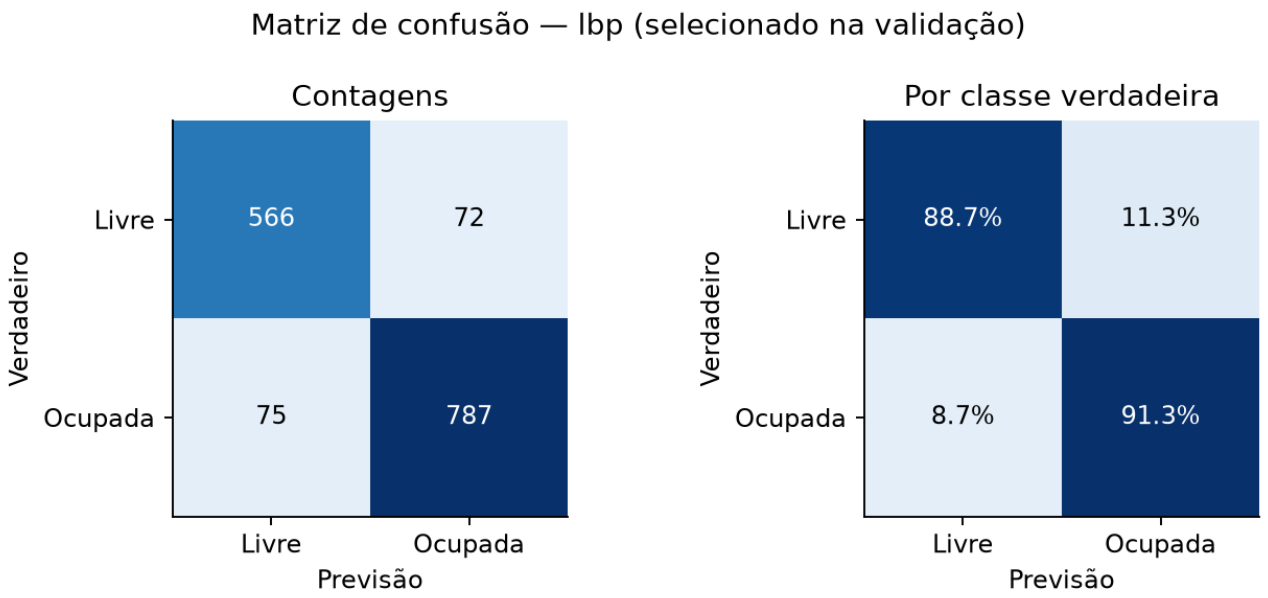


Figura 8. Matriz do modelo selecionado: contagens e percentuais por classe verdadeira.

O modelo classificou **75 vagas ocupadas como livres** e **72 livres como ocupadas**. O primeiro erro pode encaminhar alguém a uma vaga indisponível; o segundo pode ocultar uma oportunidade real. O recall da classe ocupada foi **0.9130**. Mantivemos o limiar padrão, sem favorecer uma direção de erro.

8. Custo computacional e condições climáticas

Descritor	Dim.	Ajuste (s)	Extr. ms/img	Pred. ms/img
HOG	8100	8.545	7.457	0.0239
HSV	48	0.028	1.147	0.0003
LBP	10	0.005	2.019	0.0002
Combinação	8158	5.952	6.436	0.0198
Majoritário	0	0.000	0.000	0.0001

Tabela 5. Custo de cada configuração selecionada. O ajuste corresponde ao melhor C de cada representação; o tempo total da busca é maior.

LBP descreve cada imagem com dez valores, enquanto HOG utiliza 8.100 e a combinação, 8.158. Essa diferença ajuda a interpretar o compromisso entre capacidade de representação e custo. A extração da combinação recalcula os três descritores. Os tempos também dependem da máquina, do cache e da carga; uma medição menor em um caso não estabelece que ele será sempre mais rápido. A latência de uma aplicação precisaria incluir o fluxo completo.

Clima	N	Livre	Ocup.	HOG	HSV	LBP	Combin.	Majoritário
OVERCAST	301	81	220	0.935	0.767	0.951	0.947	0.422
RAINY	606	194	412	0.894	0.786	0.886	0.909	0.405
SUNNY	593	363	230	0.901	0.816	0.876	0.928	0.279

Tabela 6. F1 macro por clima, com número de exemplos livres e ocupados em cada grupo. Combin.: combinação de HSV, LBP e HOG.

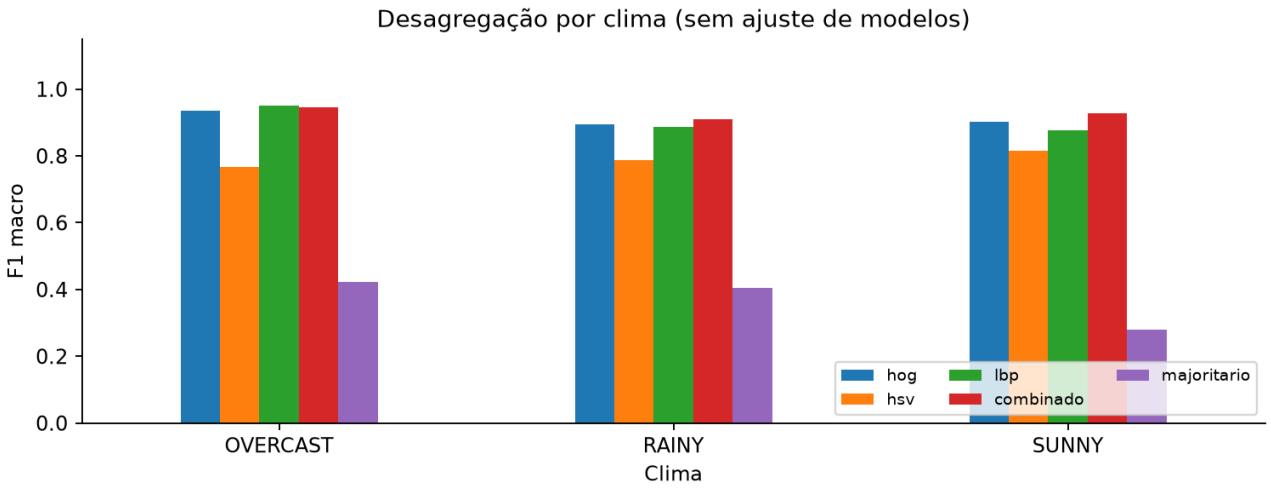


Figura 9. Desempenho dos mesmos modelos congelados nas condições climáticas do teste.

Para o modelo selecionado, o menor F1 macro ocorreu em **SUNNY (F1 macro 0.8759, n=593)**. A diferença deve ser lida junto das contagens: os grupos têm tamanhos e proporções de classe diferentes. Além disso, clima, data, iluminação e composição das cenas variam juntos. Esses resultados descrevem onde o desempenho mudou, sem isolar a causa ou avaliar um clima inédito.

9. O que os erros ajudam a entender



Figura 10. Até seis exemplos de cada direção de erro, amostrados com semente 42. Origem: CNRPark+EXT. Os identificadores estão em erros_selecionados.csv.

A inspeção do painel mostra situações diferentes. Nos erros de livre para ocupada, aparecem faixas de sombra, marcações e regiões de grama misturadas ao pavimento. No exemplo SUNNY da câmera 6, a grama ocupa grande parte do recorte; na câmera 8, há uma sombra extensa. O histograma LBP global resume todas essas texturas e descarta sua localização.

Nos erros de ocupada para livre, o exemplo OVERCAST da câmera 3 e o RAINY da câmera 3 apresentam vegetação sobre o veículo. Na câmera 1, há um veículo escuro sob sombra e outro parcialmente encoberto por elementos da cena. A última imagem, RAINY da câmera 9, é quase preta; a ocupação não pode ser confirmada visualmente a partir desse recorte. Conservou-se o rótulo oficial, sem reinterpretá-lo depois de ver a previsão.

O veículo vermelho, RAINY da câmera 5, permanece reconhecível e ainda assim foi previsto como livre. Portanto, os erros não se limitam a imagens impossíveis de interpretar. Essas observações são hipóteses sobre limitações da representação, não demonstrações causais; confirmá-las exigiria contexto das imagens completas e uma análise controlada.

Esses casos ajudam a relacionar os números às imagens, mas não medem a frequência das possíveis causas. Uma análise sistemática exigiria examinar e anotar um conjunto maior. Aqui, a inspeção serve para discutir os limites do modelo; ela não foi usada para ajustar os parâmetros ou modificar o teste.

10. Discussão e conclusão

O estudo mostrou que descritores clássicos conseguem distinguir vagas livres e ocupadas nas condições avaliadas. A configuração **LBP + SVM, C=0.01**, escolhida na validação, atingiu **0.8998 de F1 macro** no teste e superou a referência majoritária em **0.5349**. No teste, a combinação dos três descritores obteve o maior F1 macro. A escolha feita na validação foi mantida.

O contraste entre LBP e a combinação é o principal resultado da comparação. LBP oferece uma descrição compacta e foi suficiente para obter o melhor valor de validação. A combinação, por sua vez, apresentou o maior F1 macro no teste, com um vetor muito maior. Cor, textura e contornos podem se complementar, mas o benefício observado depende dos dados e deve ser considerado junto do custo. O experimento não permite escolher um vencedor universal.

Há limitações importantes: as imagens vêm de um único estacionamento, com as mesmas câmeras e vagas nas partições; utilizamos uma amostragem e uma execução de tempo; e não calculamos intervalos de confiança. Também não investigamos outros kernels, parâmetros dos descritores ou pesos para os blocos da combinação. As conclusões ficam restritas às configurações e ao subconjunto apresentados.

Para o T2, o próximo passo é comparar essa referência clássica com uma CNN, preservando o manifesto, as classes, as métricas e o teste. Uma avaliação de câmeras ou estacionamentos novos deverá ser planejada separadamente.

Reprodução do estudo

O README e docs/reproducao.md apresentam os comandos. O ambiente foi **Windows-11-10.0.26200-SP0**; o processador é identificado pelo sistema como AMD64 Family 26 Model 68 Stepping 0, AuthenticAMD. Os commits que registram o código de treinamento e avaliação são 2a2d3937a873 e b2de1ddb7641, respectivamente.

Componente	Versão
numpy	2.5.4
pandas	2.3.3
opencv-python-headless	4.14.0.94
scikit-image	0.26.0
scikit-learn	1.9.1
matplotlib	3.11.2
PyYAML	6.0.3

O arquivo requirements-lock.txt registra o ambiente completo. A identidade SHA-256 do manifesto permite conferir se uma reprodução utiliza exatamente as mesmas imagens:

`f7ac99e8b862efdf66d50f9eb641ad29540eda7213c0ce911334bc10765e58ad`

Referências

[1] Amato, G.; Carrara, F.; Falchi, F.; Gennaro, C.; Meghini, C.; Vairo, C. Deep learning for decentralized parking lot occupancy detection. Expert Systems with Applications, 72, 327-334, 2017. DOI: 10.1016/j.eswa.2016.10.055. Dataset: http://cnrpark.it/ . Arquivos oficiais: github.com/fabiocarrara/deep-parking.

[2] Dalal, N.; Triggs, B. Histograms of Oriented Gradients for Human Detection. IEEE Conference on Computer Vision and Pattern Recognition, 2005. DOI: 10.1109/CVPR.2005.177.

[3] Ojala, T.; Pietikäinen, M.; Mäenpää, T. Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns. IEEE Transactions on Pattern Analysis and Machine Intelligence, 24(7), 971-987, 2002. DOI: 10.1109/TPAMI.2002.1017623.

[4] Cortes, C.; Vapnik, V. Support-vector networks. Machine Learning, 20, 273-297, 1995. DOI: 10.1007/BF00994018.

Implementações utilizadas

OpenCV: docs.opencv.org . scikit-image: scikit-image.org/docs/stable/api/skimage.feature.html . scikit-learn: scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVC.html . As versões efetivamente utilizadas constam da seção de reprodução e dos registros do experimento.

Onde encontrar as evidências

O repositório reúne o manifesto em data/manifests/t1.csv; auditoria, parâmetros, métricas e tempos em resultados/t1/metricas/; e as previsões individuais em resultados/t1/predicoes/. Os arquivos validacao.csv, congelamento.json, teste.csv e clima.csv permitem acompanhar, respectivamente, a seleção, a escolha preservada, a avaliação final e sua divisão por clima.

As figuras de resultados ficam em resultados/t1/figuras/. As ilustrações dos métodos estão em docs/imagens/, junto dos identificadores e hashes dos exemplos de treino. Os comandos para recriá-las e a explicação de cada painel estão em docs/metodos.md.

A fonte do relatório é Markdown, acompanhada de referencias.bib e do PDF. Os dados brutos e os modelos treinados ficam fora do Git; a documentação explica como obtê-los ou recriá-los.